

1. PROJE ÖZETİ — 5 PUAN

Bu bölümde amaç yalnızca kısa tanıtım yapmak değildir. Jüriye projenin **ne problem çözdüğünü, hangi bileşenlerden oluştuğunu, yapay zekâ ve 5G'nin projedeki gerçek rolünü, çıktıların nasıl üretildiğini ve sistemin neden güvenilir olduğunu** özet biçimde anlatmak gerekir.

1.1. Projenin Adı ve Amacı

Projenin adı **SİNAPTİC5G**'dir. SİNAPTİC5G, yol kenarı kamerası veya araç kamerası üzerinden alınan video görüntülerinde; araç, araç rengi, plaka bölgesi, sürücü davranışları ve riskli durumları analiz eden yapay zekâ destekli bir yol güvenliği sistemidir.

Sistemin temel amacı, trafik güvenliği açısından kritik video verilerini işleyerek;

- ana aracın tespit edilmesi,
- aracın tip ve renk bilgisinin çıkarılması,
- Türkiye plaka bölgesinin algılanması,
- sürücünün riskli davranışlarının tespit edilmesi,
- olayların zamansal olarak takip edilmesi,
- yarışma formatına uygun `results.json` çıktısının güvenli biçimde üretilmesi,
- canlı kullanım senaryosunda ise 5G ağ yetenekleri ile düşük gecikmeli analiz yapılmasıdır.

Bu yönüyle proje yalnızca bir nesne tespit modeli değildir. SİNAPTİC5G; model bütünlüğü denetimi, takip algoritması, çıktı şeması doğrulama, atomik dosya yazımı, WebRTC tabanlı canlı görüntü aktarımı ve CAMARA tabanlı 5G ağ yönetimini birleştiren uçtan uca bir mühendislik çözümüdür.

1.2. Projenin Kapsamı

Proje iki temel çalışma kipine sahiptir:

Çalışma Kipi	Açıklama	Amaç
Çevrimdışı FTR / Edge Kipi	Docker ortamında verilen video dosyası işlenir ve resmi yarışma çıktısı olan <code>results.json</code> üretilir.	Yarışma değerlendirme sürecinde dış servislere bağımlı olmadan güvenilir çıktı üretmek
Canlı 5G / WebRTC Kipi	Android cihazdan alınan kamera görüntüsü WebRTC ile GPU sunucusuna aktarılır, analiz sonuçları kimlikli olay telemetrisi olarak geri döner.	Gerçek zamanlı yol güvenliği senaryosunda düşük gecikmeli analiz ve 5G ağ yeteneklerini kullanmak

Bu ayırım özellikle önemlidir. Çevrimdışı yarışma değerlendirme hattı; Android, Redis, CAMARA, Turkcell erişimi veya internet bağlantısına ihtiyaç duymaz. Böylece yarışma değerlendirme süreci dış servis kesintilerinden etkilenmez. Canlı kip ise gerçek dünya kullanımı için tasarlanmıştır ve görüntüyü doğrudan WebRTC medya düzlemi üzerinden GPU tarafına taşır.

1.3. Kullanılan Yapay Zekâ Yaklaşımı

Projede iki ana tespit modeli kullanılmaktadır:

1. YOLOv8n COCO modeli

Genel araç ve nesne tespiti için kullanılır.

2. Özel eğitilmiş YOLOv8m modeli

Sürücü davranışları, plaka bölgesi ve yarışmaya özel sınıfların tespiti için kullanılır.

Özel model dokuz sınıf üzerinden eğitilmiştir:

ID	Sınıf
0	telefonla_konusma
1	su_icme
2	arkaya_bakma
3	esneme
4	sigara_icme
5	emniyet_kemer_ihlali
6	teknocan
7	bilgisayar
8	license_plate

Model çıktıları doğrudan resmi yarışma çıktısına yazılmaz. Önce takip, güven skoru düzenleme, etiket adaptasyonu, plaka doğrulama ve JSON şema kontrolünden geçirilir.

1.4. Projede 5G'nin Rolü

Projede 5G yalnızca “bağlantı teknolojisi” olarak ele alınmamıştır. Canlı kullanım senaryosunda 5G, düşük gecikmeli video aktarımı ve ağ kalitesi yönetimi için kullanılır.

Canlı kipte Android cihazdan gelen kamera görüntüsü, WebRTC üzerinden GPU medya servisine aktarılır. BFF katmanı ham video taşımaz; yalnızca kimlik, oturum, SDP/ICE sinyalleşmesi ve QoD orkestrasyonu gibi kontrol görevlerini yürütür. Böylece ham görüntünün gereksiz şekilde uygulama sunucusu veya Redis üzerinde taşınması önlenir.

CAMARA tabanlı 5G yetenekleri iki temel amaçla ele alınır:

- **Number Verification:** Kullanıcı/cihaz doğrulaması için.
- **Quality on Demand:** Riskli durumda ağ kalitesi talebinin kontrollü biçimde tetiklenmesi için.

QoD çağrısı her durumda yapılmaz. Sistem, yalnızca hedef varlık mevcutsa, araç yaklaşma davranışı gösteriyorsa, aynı cihaz için aktif QoD oturumu yoksa ve kalibre edilmiş fayda modeli olumlu sonuç veriyorsa QoD çağrısını başlatır. Bu yaklaşım, ağ kaynaklarının gereksiz kullanılmasını engeller.

1.5. Projenin Güçlü Yanları

SİNAPTİC5G'nin güçlü yönleri şunlardır:

Güçlü Yön	Açıklama
İki kipli mimari	Yarışma değerlendirme hattı dış servislere bağımlı değildir; canlı kullanım hattı ise 5G ve WebRTC ile gerçek zamanlı çalışmaya uygundur.
Model byte kilidi	Kullanılan model dosyalarının SHA-256 hash değerleri doğrulanır. Değiştirilmiş modelle sessizce çalışma engellenir.
Şema doğrulama	Çıktı JSON dosyası resmi şemaya göre kontrol edilir. Enum dışı etiketler veya geçersiz güven skorları dışarı sızmaz.
Atomik çıktı yazımı	<code>results.json</code> dosyası önce geçici dosyaya yazılır, ardından <code>fsync</code> ve <code>os.replace</code> ile güvenli biçimde hedef dosyanın yerini alır.
Sentinel yaklaşımı	OCR doğruluğu kanıtlanmadığında rastgele plaka üretmek yerine <code>01A0000</code> ve <code>0.0</code> güven değeri döndürülür.
Takip sistemi	IoU, kuşbakışı mesafe, renk histogramı ve Kalman filtresi birlikte kullanılarak kimlik karışmaları azaltılır.
Kanıt disiplini	Ölçülmüş sonuçlar, hedefler ve uyarılar raporda açıkça ayrılır.

1.6. Ölçülmüş Başlıca Sonuçlar

Proje kapsamında elde edilen başlıca ölçümler aşağıdaki gibidir:

Ölçüm	Sonuç	Durum
Özel dedektör mAP@0.50	0,7457	Ölçüldü
Özel dedektör mAP@0.50:0.95	0,4710	Ölçüldü
Precision	0,7930	Ölçüldü
Recall	0,7510	Ölçüldü
F1-Score	0,7714	Hesaplandı
Yazılım regresyon testleri	39/39 geçti	Ölçüldü
CPU uçtan uca smoke süresi	Ortalama 15,19 sn	Ölçüldü, 8 sn hedefi karşılanmadı
OCR gecikmesi	CPU FP32 p50 59,65 ms	Ölçüldü
OCR doğruluğu	Henüz ölçülmedi	Hedef
T4 GPU kabul testi	Henüz tamamlanmadı	Hedef
Gerçek CAMARA/Turkcell çağırısı	Henüz tamamlanmadı	Hedef

Bu tabloda özellikle "ölçüldü" ve "hedef" ayrımı yapılmıştır. Projede henüz tamamlanmamış kabul adımları gerçekleşmiş sonuç gibi sunulmamıştır.

2. VERİSETİ OLUŞTURULMASI — 20 PUAN

Bu bölüm raporun en kritik bölümlerinden biridir. Burada yalnızca hangi veri setlerinin kullanıldığını değil, verilerin nasıl toplandığını, nasıl birleştirildiğini, hangi sınıflara dönüştürüldüğünü, eğitim/doğrulama/test ayırımının nasıl yapıldığını, sınıf dengesizliğiyle nasıl mücadele edildiğini ve veri artırma yöntemlerinin nasıl uygulandığını açıklamak gerekir.

2.1. Veri Kaynakları

Model eğitimi için açık kaynaklı veri setleri ve yerel test videoları kullanılmıştır. Açık kaynaklı veri setleri; sürücü davranışı, dikkat dağınıklığı, emniyet kemeri ihlali, sigara kullanımı, yorgunluk/esneme ve Türkiye plakası gibi yarışma açısından önemli sınıfları kapsayacak şekilde seçilmiştir.

Kullanılan veri kaynakları aşağıdaki tabloda verilmiştir:

Veri Kaynağı	Kullanım Amacı	Lisans / Durum
Driver Distraction Detection	Telefonla konuşma, mesajlaşma, su içme, arkaya bakma gibi sürücü dikkat dağınıklığı davranışları	CC BY 4.0
Driver Drowsiness YOLO	Esneme ve yorgunluk görünümü	CC BY 4.0
Cigarette Smokers	Sigara içme davranışı	CC BY 4.0
Detect Seatbelt	Emniyet kemeri ihlali	CC BY 4.0
Turkish License Plate Dataset	Türkiye plaka bölgesi tespiti	CC0-1.0
Yerel video_1, video_2, video_3	Smoke/entegrasyon ve yerel gözlem amaçlı	Onay kaydı tamamlanmadan eğitimde kullanılmamalı

Açık kaynak veri setlerinin lisansları ayrıca kaynakça bölümünde belirtilmiştir. Yerel videolar için kişi/çekim onay kayıtları tamamlanmadan bu veriler eğitim başarısı iddiasında kullanılmamalıdır.

2.2. Etiket Sözlüğü ve Sınıf Birleştirme

Farklı veri setlerinden gelen etiketler her zaman aynı isimlendirme standardına sahip değildir. Örneğin bir veri setinde “phone”, başka bir veri setinde “calling” veya “texting” olarak geçen etiketler aynı yarışma sınıfını temsil edebilir. Bu nedenle tüm veri setleri eğitim öncesinde tek bir kanonik etiket sözlüğüne dönüştürülmüştür.

Kanonik Sınıf	Kaynak Etiket Örnekleri	Açıklama
telefonla_konusma	phone, calling, texting	Telefonla konuşma veya telefon kullanımı
su_icme	drinking, drink	Sürücünün su/içecek içmesi

Kanonik Sınıf	Kaynak Etiket Örnekleri	Açıklama
arkaya_bakma	reaching_behind, looking_back	Sürücünün arka tarafa bakması veya uzanması
esneme	yawn, yawning	Yorgunluk veya uykululuk göstergesi
sigara_icme	cigarette, smoking, vaping	Sigara veya benzeri davranış
emniyet_kemer_ihlali	no_seatbelt, unbelted	Emniyet kemerinin takılı olmaması
teknocan	teknocan	Yarışmaya özel nesne
bilgisayar	laptop, computer	Bilgisayar/laptop nesnesi
license_plate	plate, licence_plate	Plaka bölgesi

Bu etiket birleştirme adımı sayesinde farklı veri kaynaklarından gelen sınıflar tek bir model eğitim formatında toplanmıştır. Modelin iç sınıf kimliği ile yarışma JSON çıktısındaki resmi etiketler ayrı tutulmuştur. Böylece dış çıktı sözleşmesi yalnızca adaptör katmanında üretilmiştir.

2.3. Veri Temizleme ve Hazırlama

Veri seti oluşturulurken aşağıdaki temizleme ve hazırlama adımları uygulanmıştır:

1. Bozuk görüntülerin ayıklanması

Okunamayan, çözünürlüğü geçersiz veya etiket dosyasıyla eşleşmeyen görüntüler veri setinden çıkarılmıştır.

2. Etiket formatlarının dönüştürülmesi

Farklı kaynaklardan gelen anotasyonlar YOLO formatına uygun hale getirilmiştir.

3. Sınıf adlarının normalize edilmesi

Farklı veri setlerinde aynı anlamı taşıyan etiketler tek kanonik sınıf altında birleştirilmiştir.

4. Plaka veri setinin sınırlandırılması

Plaka veri setinin davranış sınıflarını baskılamaması için plaka örnekleri belirli bir üst sınırla sınırlandırılmıştır.

5. Train/validation/test ayrımı

Eğitim, doğrulama ve test ayrımı fiziksel dosya listeleriyle yapılmıştır. Aynı video, kişi, araç veya oturma farklı split'lere sızması hedeflenmiştir.

6. Manifest ve hash üretimi

Veri dosyalarının yolları, split bilgileri ve SHA-256 hash değerleri manifest dosyasında takip edilmiştir.

2.4. Eğitim, Doğrulama ve Test Dağılımı

Kilitli mevcut eğitim koşusunda veri dağılımı yaklaşık olarak aşağıdaki gibidir:

Split	Görüntü Sayısı	Oran	Instance Sayısı
Eğitim	11.649	%81,17	14.533
Doğrulama	1.559	%10,86	2.313
Test	1.144	%7,97	1.744
Toplam	14.352	%100	18.590

Bu dağılım modelin ölçülmüş mevcut mAP sonuçlarının kaynağıdır. Ancak bu dağılım tam olarak 70/20/10 değildir. Bu nedenle raporda mevcut ölçümlerin 70/20/10 üzerinden alındığı iddia edilmemelidir.

Final hedefi olarak önerilen veri politikası şudur:

Split	Hedef Oran	Gerekçe
Eğitim	%70	Modelin dokuz sınıfı öğrenebilmesi için yeterli veri sağlar.
Doğrulama	%20	Güven eşiği, NMS eşiği, augmentasyon etkisi ve erken durdurma kararlarının daha sağlıklı ayarlanmasını sağlar.
Test	%10	Eğitim ve eşik seçiminden bağımsız nihai başarı ölçümü sağlar.

70/20/10 dağılımı özellikle grup-bilinçli uygulanmalıdır. Aynı kişinin, aynı aracın, aynı kameranın veya aynı video oturumunun hem eğitim hem test setinde bulunması model başarısını olduğundan yüksek gösterebilir. Bu nedenle split işlemi yalnızca rastgele dosya ayırma şeklinde değil, mümkün olduğunca video/kiş/araç/oturum gruplarına göre yapılmalıdır.

2.5. Sınıf Dengesizliği

Veri setinde sınıflar arasında belirgin dengesizlik bulunmaktadır. Örneğin sigara içme sınıfı çok yüksek instance sayısına sahipken, bazı sınıflarda test desteği çok düşüktür veya hiç yoktur. Bu durum modelin global mAP değerini yanıltıcı hale getirebilir.

Bu nedenle sınıf bazlı destek açıkça raporlanmalıdır. Özellikle şu noktalar belirtilmelidir:

- Sigara sınıfı global başarıyı baskın biçimde etkileyebilir.
- Telefonla konuşma, teknocan ve bilgisayar gibi sınıflarda bağımsız test desteği yoksa bu sınıflar için başarı iddiası kurulamaz.
- Su içme, arkaya bakma ve emniyet kemeri ihlali gibi düşük destekli sınıflarda metriklerin güven aralığı geniştir.
- Dummy veya tamamen sentetik görüntüler test setinde başarı kanıtı olarak kullanılmamalıdır.

Sınıf dengesizliğiyle mücadele için uygulanan veya uygulanması gereken yöntemler:

Yöntem	Açıklama
Azınlık sınıf augmentasyonu	Az örnekli sınıflarda parlaklık, kontrast, ölçek, çevirme, bulanıklık gibi dönüşümler uygulanır.

Yöntem	Açıklama
Baskın sınıf sınırlandırma	Çok baskın sınıfların eğitimde modeli domine etmesi önlenir.
Sınıf bazlı metrik raporlama	Sadece global mAP değil, her sınıf için precision, recall ve AP değerleri verilir.
Gerçek test desteği hedefi	Her sınıf için minimum gerçek test örneği hedefi belirlenir.
Dummy verinin dışlanması	Dummy/sentetik örnekler doğrulama ve test başarı kanıtı olarak kullanılmaz.

2.6. Veri Artırma Teknikleri

Modelin farklı ışık, kamera açısı, hareket bulanıklığı ve çevresel koşullara dayanıklı olması için veri artırma teknikleri uygulanmıştır.

Kullanılan veri artırma yöntemleri şunlardır:

Veri Artırma Tekniği	Amaç
HSV renk değişimi	Farklı ışık ve kamera renk koşullarına dayanıklılık sağlamak
Parlaklık/kontrast değişimi	Gündüz/gece, gölge ve parlama etkilerine karşı genelleme sağlamak
Yatay çevirme	Sürücü davranışlarının farklı yönlerdeki görünümünü artırmak
Ölçekleme ve öteleme	Nesnelerin farklı uzaklık ve konumlardaki görünümüne dayanıklılık sağlamak
Gauss gürültüsü	Kamera sensör gürültüsüne karşı dayanıklılık sağlamak
Hareket bulanıklığı	Araç hareketi ve düşük enstantane etkilerine karşı dayanıklılık sağlamak
Mosaic augmentation	YOLO eğitiminde farklı nesne bağlamlarını birleştirerek öğrenmeyi güçlendirmek
Close mosaic	Eğitimin son bölümünde gerçek görüntü geometrisine dönerek modelin gerçek dağılıma uyumunu artırmak

Veri artırma yalnızca eğitim setinde uygulanmalıdır. Doğrulama ve test setlerinde augmentasyon uygulanması, gerçek başarı ölçümünü bozabilir.

2.7. Veri Seti Bölümü İçin Kanıtlar

Bu bölümde aşağıdaki kanıtların rapora eklenmesi önerilir:

Kanıt	Açıklama
<code>LICENSE_INVENTORY.md</code>	Kullanılan veri setlerinin lisans kanıtı

Kanıt	Açıklama
<code>training_dataset_manifest.yaml</code>	Veri yolları, split bilgisi ve SHA-256 hashleri
<code>class_support_report.csv</code>	Sınıf bazlı örnek sayıları
<code>train.txt</code> , <code>val.txt</code> , <code>test.txt</code>	Fiziksel split listeleri
Örnek anotasyon görselleri	Etiket kalitesini göstermek için
Sınıf histogramı	Veri dengesizliğini görselleştirmek için
Veri temizleme raporu	Çıkarılan bozuk veya geçersiz örnekler

3. YAPAY ZEKÂ ÇÖZÜMÜ — 50 PUAN

Bu bölüm raporun en yüksek puanlı bölümüdür. Burada yalnızca model adı yazmak yeterli değildir. Problemin neden zor olduğu, seçilen çözümün neden uygun olduğu, mimarinin nasıl çalıştığı, modelin hangi aşamalardan geçtiği ve çıktının nasıl güvenli hale getirildiği detaylı anlatılmalıdır.

3.1. Problemin Analizi — 15 PUAN

Video üzerinden araç, plaka, hız ve riskli sürücü davranışı tespiti; tek karelik basit bir sınıflandırma problemi değildir. Gerçek trafik ortamında kamera açısı, ışık koşulları, araç hareketi, nesne örtüşmeleri, düşük çözünürlük, plaka bulanıklığı ve değişken FPS gibi birçok problem aynı anda ortaya çıkar.

3.1.1. Işık Değişimleri

Trafik videolarında ışık koşulları sürekli değişebilir. Gündüz/gece farkı, tünel çıkışları, far parlaması, gölge, güneş yansıması ve kamera otomatik pozlama değişimleri modelin algılama başarısını etkiler.

Bu durum özellikle araç rengi ve plaka bölgesi tespiti için kritiktir. Araç rengi RGB uzayında doğrudan değerlendirildiğinde ışık değişimlerinden fazla etkilenebilir. Bu nedenle araç rengi çıkarımında HSV renk uzayı kullanılmıştır. Düşük doygunluk durumlarında beyaz, gri ve siyah ayrımı V kanalı üzerinden yapılırken; kromatik renkler H aralıklarıyla değerlendirilir.

Tercih edilen çözüm yolu:

- Görüntü işleme tarafında HSV tabanlı renk çıkarımı,
- OCR ön işlemede CLAHE kullanımı,
- Eğitim aşamasında HSV, parlaklık ve kontrast augmentasyonu,
- Düşük güvenli renk tahminlerinde güven skorunun azaltılmasıdır.

Bu yaklaşım, ışık değişimlerinin model çıktısını doğrudan bozmasını azaltmak için tercih edilmiştir.

3.1.2. Hareket Bulanıklığı

Araçların hızlı hareket etmesi, kameranın titreşmesi veya düşük enstantane nedeniyle görüntüde hareket bulanıklığı oluşabilir. Hareket bulanıklığı özellikle küçük nesnelerde ciddi sorun yaratır. Plaka, sigara, telefon ve emniyet kemeri gibi küçük veya ince detaylı sınıflar bu durumdan daha fazla etkilenir.

Çözüm yaklaşımı:

- Eğitimde hareket bulanıklığı augmentasyonu uygulanmıştır.
- Plaka ve küçük nesneler için 640x640 giriş çözünürlüğü kullanılmıştır.
- Düşük güvenli tespitler doğrudan elenmek yerine takip hattında zamansal olarak değerlendirilebilir.
- Aynı nesne birden fazla karede görülüyorsa karar tek kareye göre değil, track boyunca birleştirilerek verilir.

Bu yaklaşım, tek karedeki hataları azaltmak ve zamansal tutarlılığı artırmak için tercih edilmiştir.

3.1.3. Oklüzyon ve Nesne Örtüşmesi

Trafikte araçlar birbirini kapatabilir. Sürücü davranışı tespitinde ise el, yüz, telefon, direksiyon ve emniyet kemeri gibi nesneler birbirine yakın bölgelerde bulunur. Bu durum false positive ve false negative hatalarına yol açabilir.

Çözüm yaklaşımı:

- Takip sisteminde yalnızca IoU kullanılmamıştır.
- IoU'ya ek olarak kuşbakışı düzlem mesafesi, HSV histogram benzerliği ve Kalman filtresi kullanılmıştır.
- Kayıp izler kısa süreli tamponda tutulmuştur.
- Düşük güvenli tespitler ikinci aşama eşleştirme ile değerlendirilebilmiştir.

Bu sayede kısa süreli kapanma durumlarında nesne kimliğinin tamamen kaybolması veya ID switch oluşması azaltılmıştır.

3.1.4. Küçük Nesne Problemi

Plaka, telefon, sigara ve emniyet kemeri gibi hedefler görüntü içinde küçük alan kaplayabilir. Küçük nesnelerde hem tespit hem de sınıflandırma zordur. Plaka için kutu tespiti güçlü olsa bile OCR aşaması ayrıca zorluk içerir.

Çözüm yaklaşımı:

- Özel YOLOv8m modeli kullanılmıştır.
- Küçük nesneler için model giriş çözünürlüğü 640x640 olarak belirlenmiştir.
- NMS ve confidence eşikleri dikkatli seçilmiştir.
- Plaka için tespit başarımı ile OCR başarımı ayrı değerlendirilmiştir.
- OCR doğruluğu kanıtlanmadığında sentinel çıktı üretilmiştir.

Bu noktada önemli olan, plaka kutusu başarısını OCR başarısı gibi göstermemektir. Plaka tespiti ayrı, karakter okuma doğruluğu ayrı bir metrikle değerlendirilmelidir.

3.1.5. Değişken FPS ve Hız Kestirimi

Video kareleri arasındaki süre her zaman sabit olmayabilir. Sabit kare sayısına göre hız hesaplamak, kare düşmesi veya değişken FPS durumunda fiziksel olarak hatalı sonuç verebilir.

Çözüm yaklaşımı:

- Nesnenin kutu alt orta noktası kuşbakışı düzleme taşınır.
- Ardışık konum farkı gerçek zaman damgası farkına bölünür.
- Kalman filtresinde geçiş matrisi her karede `dt` değerine göre güncellenir.
- Homografi kalibrasyonu yoksa mutlak hız doğruluğu iddia edilmez.

Bu yaklaşım, hız kestiriminin yalnızca piksel hareketine değil, zaman bilgisine dayalı yapılmasını sağlar.

3.1.6. OCR Belirsizliği

Plaka OCR problemi, plaka kutusu tespitinden daha zordur. Çünkü karakterler küçük, bulanık, eğik veya kısmen kapanmış olabilir. Ayrıca Türk plakalarında il kodu, harf ve sayı dizilimi belirli kurallara uymalıdır.

Çözüm yaklaşımı:

- OCR model dosyaları sistemde bulunur.
- Plaka çıktısı regex ve format kontrolünden geçirilir.
- Geçerli OCR sonucu yoksa sentinel değer kullanılır.
- Rastgele veya tahmini plaka üretilmez.

Bu yaklaşım güvenlik açısından önemlidir. Sistem emin olmadığı plakayı gerçekmiş gibi yazmak yerine güven değeri düşük sentinel çıktı üretir.

3.2. Çözüm Mimarisi — 15 PUAN

Bu bölümde sistemin kuşbakışı mimarisi anlatılmalıdır. Ham videonun sisteme girişinden resmi çıktının üretilmesine kadar geçen süreç net biçimde gösterilmelidir.

3.2.1. Çevrimdışı FTR Mimarisi

Çevrimdışı değerlendirme hattı aşağıdaki adımlardan oluşur:

```
Video Girişi
↓
Kare Okuma ve Zaman Tabanlı Örnekleme
↓
YOLOv8n COCO Modeli + Özel YOLOv8m Modeli
↓
NMS ve Güven Skoru Filtreleme
↓
Araç / Plaka / Davranış Tespitleri
↓
```

```
IoU + BEV + HSV + Kalman Tabanlı Takip
↓
Zamansal Olay Agregasyonu
↓
Yarışma Etiket Adaptörü
↓
JSON Schema Doğrulama
↓
Atomik results.json Yazımı
```

Bu hatta dış servis bağımlılığı bulunmaz. Sistem Docker ortamında verilen videoyu işler ve resmi yarışma çıktısını üretir.

3.2.2. Canlı 5G / WebRTC Mimarisi

Canlı kullanım senaryosunda mimari şu şekildedir:

```
Android CameraX
↓
WebRTC RTP/RTCP Medya Aktarımı
↓
GPU Medya Servisi
↓
Latest-frame Kuyruğu
↓
ONNX Runtime Inference
↓
Risk / Araç / Plaka / Davranış Tespiti
↓
Olay Telemetrisi
↓
Android Arayüzü
```

Kontrol düzlemi ise ayrı çalışır:

```
Android Uygulama
↓
BFF
↓
OAuth / JWT
↓
SDP / ICE Sinyalleşmesi
↓
Redis TTL Posta Kutusu
↓
CAMARA Number Verification / QoD Orkestrasyonu
```

Bu ayırım sayesinde ham video BFF veya Redis üzerinden taşınmaz. BFF yalnızca kimlik, oturum ve ağ orkestrasyonu görevlerini yürütür.

3.2.3. Bileşenler

Bileşen	Görev
Android CameraX	Kamera görüntüsünü alır ve canlı video kaynağı sağlar.
WebRTC	Görüntüyü düşük gecikmeli şekilde GPU servisine taşır.
GPU Medya Servisi	WebRTC akışını alır, kareleri çözer ve inference hattına aktarır.
ONNX Runtime	YOLO modellerini çalıştırır.
Tracking Pipeline	Tespitleri zamansal olarak izler ve kimlik tutarlılığı sağlar.
Competition Contract	Model çıktısını resmi yarışma JSON formatına dönüştürür.
JSON Schema Validator	Çıktının resmi şemaya uyduğunu doğrular.
BFF	Kimlik, oturum ve CAMARA orkestrasyonunu yönetir.
Redis	Kısa ömürlü SDP/ICE ve QoD kilit bilgisini tutar.
CAMARA APIs	Number Verification ve Quality on Demand yeteneklerini sağlar.

3.2.4. Veri Düzlemi ve Kontrol Düzlemi Ayrımı

Mimaride veri düzlemi ve kontrol düzlemi bilinçli olarak ayrılmıştır.

Düzlem	Taşıdığı Veri	Taşımadığı Veri
Medya düzlemi	Kodlanmış canlı video, RTP/RTCP paketleri	OAuth sırrı, kalıcı kimlik bilgisi
Kontrol düzlemi	JWT, SDP/ICE, QoD kararları	Ham video, frame, görüntü içeriği
Telemetri düzlemi	Event ID, risk bilgisi, latency, dropped frame	Ham plaka görüntüsü veya kalıcı video

Bu ayırım güvenlik, performans ve ölçeklenebilirlik açısından önemlidir. Ham görüntünün gereksiz şekilde BFF veya Redis'e alınmaması hem gecikmeyi hem de veri sızıntısı riskini azaltır.

3.2.5. Çıktı Üretim Mimarisi

Sistemin resmi çıktısı `results.json` dosyasıdır. Bu dosya doğrudan model çıktısından oluşmaz. Önce aşağıdaki kontrollerden geçer:

1. Etiketler resmi yarışma enum değerlerine dönüştürülür.
2. Güven skorları 0-1 aralığına sıkıştırılır.
3. Geçersiz veya NaN değerler temizlenir.
4. Plaka formatı regex ile kontrol edilir.
5. OCR geçerli değilse sentinel değer kullanılır.

6. JSON Schema doğrulaması yapılır.

7. Dosya atomik olarak yazılır.

Bu sayede sistemin resmi çıktısı hem format olarak hem de mühendislik güvenliği açısından kontrol altına alınır.

3.3. Çözüm Detayları — 20 PUAN

Bu bölümde model mimarisi, eğitim parametreleri, ön işleme, son işleme, takip, OCR, donanım/yazılım altyapısı ve güvenlik kontrolleri teknik biçimde anlatılmalıdır.

3.3.1. Kullanılan Derin Öğrenme Modelleri

Projede YOLO tabanlı nesne tespit mimarisi kullanılmıştır. YOLO ailesi, tek aşamalı tespit yaklaşımı sayesinde gerçek zamanlı veya yarı gerçek zamanlı video analizi için uygundur.

Model	Kullanım Amacı
YOLOv8n COCO	Genel araç ve nesne tespiti
Özel YOLOv8m	Sürücü davranışı, plaka ve yarışmaya özel sınıflar
LPRNet / CRNN ONNX	Plaka OCR denemeleri
TFLite model	Alternatif mobil/edge kullanım olasılığı

YOLOv8m, YOLOv8n'e göre daha büyük bir modeldir. Bu nedenle özel sınıflarda daha yüksek temsil kapasitesi sağlar. Plaka, sigara, telefon ve emniyet kemeri gibi küçük veya detaylı nesneler için daha büyük omurgaya sahip özel model tercih edilmiştir.

3.3.2. Eğitim Parametreleri

Kilitli eğitim koşusunun ana parametreleri şunlardır:

Parametre	Değer
Model	YOLOv8m
Giriş çözünürlüğü	640x640
Epoch	120
Batch size	16
AMP	Açık
Dondurulan katman	İlk 10 katman
Mosaic	Açık
Close mosaic	Son 10 epoch
Seed	0

Parametre	Değer
Deterministik çalışma	Açık
Cihaz	CUDA device 0

Bu parametreler, modelin hem önceden öğrenilmiş görsel özelliklerden yararlanmasını hem de yarışmaya özel sınıflara adapte olmasını sağlar.

3.3.3. Ön İşleme

Video ve görüntüler modele verilmeden önce belirli ön işleme adımlarından geçirilir:

Ön İşleme Adımı	Açıklama
Kare okuma	Video kareleri OpenCV ile okunur.
Zaman tabanlı örnekleme	Kare seçiminde zaman bilgisi dikkate alınır.
Yeniden boyutlandırma	Model girişine uygun 640x640 formatı hazırlanır.
Renk uzayı işlemleri	Araç rengi için HSV dönüşümü yapılır.
OCR crop hazırlığı	Plaka bölgesi kırılır ve OCR ön işlemeye alınır.
CLAHE	OCR için kontrast iyileştirme amacıyla kullanılır.

3.3.4. Model Çıkarımı

Model çıkarımı ONNX Runtime ile yapılır. Sağlayıcı sırası şu şekildedir:

CUDAExecutionProvider → CpuExecutionProvider

CUDA varsa GPU kullanılır, yoksa CPU üzerinden çalışma devam eder. Bu yapı, sistemin farklı donanımlarda çalışabilmesini sağlar.

FTR Docker hattında PyTorch veya Ultralytics çalışma zamanı zorunlu tutulmaz. Dağıtım için ONNX model artefaktları kullanılır. Bu sayede imaj boyutu ve çalışma zamanı bağımlılıkları azaltılır.

3.3.5. Son İşleme

Model çıktıları sonrasında aşağıdaki adımlar uygulanır:

Son İşleme Adımı	Açıklama
Confidence filtreleme	Düşük güvenli tespitler elenir veya takipte düşük öncelikte değerlendirilir.
NMS	Çakışan kutular Non-Maximum Suppression ile azaltılır.
Sınıf adaptasyonu	Model sınıfları yarışma etiketlerine dönüştürülür.

Son İşleme Adımı	Açıklama
Güven skoru sınırlandırma	Skorlar 0–1 aralığında tutulur.
Geçersiz değer temizleme	NaN veya sonsuz değerler resmi çıktıya yazılmaz.
Temporal agregasyon	Aynı olayın birden fazla karedeki tespitleri birleştirilir.

3.3.6. Takip Sistemi

Takip sistemi, video boyunca aynı nesnenin kimliğini korumayı hedefler. Bunun için birden fazla sinyal birlikte kullanılır:

Sinyal	Görev
IoU	Ardışık karelerdeki kutu örtüşmesini ölçer.
BEV mesafesi	Nesnenin kuşbakışı düzlemdeki fiziksel yakınlığını değerlendirir.
HSV histogramı	Araç görünüm/renginin benzerliğini kullanır.
Kalman filtresi	Nesne hareketini tahmin eder ve ölçüm gürültüsünü azaltır.
Kamera hareket telafisi	Global kamera ötelemesini azaltır.

Bu yaklaşım, yalnızca IoU'ya dayalı takipten daha dayanıklıdır. Özellikle hızlı yanal geçişler, kısa süreli kapanmalar ve yakın araçlar arasında kimlik karışmasını azaltmak için tercih edilmiştir.

3.3.7. Araç Rengi Çıkarımı

Araç rengi, aracın gövde bölgesini temsil eden ROI üzerinden çıkarılır. RGB yerine HSV renk uzayı tercih edilmiştir. Çünkü HSV, renk tonunu parlaklıktan daha iyi ayırır.

Yaklaşım:

1. Araç kutusundan gövdeye karşılık gelen orta bant seçilir.
2. ROI HSV uzayına dönüştürülür.
3. Düşük doygunlukta beyaz/gri/siyah ayrımı V kanalıyla yapılır.
4. Kromatik renkler H aralıklarına göre sınıflandırılır.
5. Histogram dağılımı karışık renk güveni düşürülür.

3.3.8. Plaka Tespiti ve OCR

Plaka için iki aşamalı yaklaşım kullanılmıştır:

1. Plaka kutusu tespiti

YOLOv8m modeli plaka bölgesini tespit eder.

2. OCR / karakter okuma

LPRNet veya CRNN tabanlı OCR modelleri ile karakter okuma denenir.

Ancak OCR doğruluğu bağımsız bir Türk plaka test seti üzerinde henüz kanıtlanmadıysa, raporda bu durum açıkça belirtilmelidir. Plaka kutusu AP değerleri OCR başarısı olarak sunulmamalıdır.

OCR güvenilir olmadığında sistem sentinel davranışı uygular:

```
plaka: 01A0000
guven: 0.0
```

Bu yaklaşım, sistemin bilinmeyen veya doğrulanmamış plakaları gerçekmiş gibi üretmesini engeller.

3.3.9. JSON Şeması ve Çıktı Güvenliği

Resmi çıktı `results.json` dosyasıdır. Bu dosyada yalnızca yarışma şemasının izin verdiği alanlar bulunmalıdır. Şema dışı alanlar kabul edilmez.

Uygulanan kontroller:

Kontrol	Amaç
<code>additionalProperties=false</code>	Şema dışı alanları engellemek
Enum kontrolü	Geçersiz araç tipi, renk veya etiketleri engellemek
Regex kontrolü	Plaka formatını doğrulamak
Güven skoru aralığı	0-1 dışında skor yazılmasını engellemek
NaN/sonsuz kontrolü	Geçersiz sayısal değerleri engellemek
Atomik yazım	Yarım veya bozuk JSON dosyasını engellemek

Atomik yazım süreci şu şekildedir:

```
Geçici dosyaya yaz
↓
Buffer flush
↓
fsync
↓
os.replace ile hedef dosyanın yerini değiştir
```

Bu sayede işlem yarıda kesilse bile bozuk JSON dosyası resmi çıktı gibi görünmez.

3.3.10. Donanım ve Yazılım Altyapısı

Katman	Kullanılan Teknoloji
Model eğitimi	Ultralytics YOLO
Model çıkarımı	ONNX Runtime

Katman	Kullanılan Teknoloji
Görüntü işleme	OpenCV
Şema doğrulama	jsonschema
API katmanı	FastAPI
Canlı medya	WebRTC, aiortc
Mobil kamera	Android CameraX
Kısa ömürlü oturum verisi	Redis
5G API	CAMARA Number Verification, Quality on Demand
Konteyner	Docker, NVIDIA CUDA tabanlı imaj
Model formatı	ONNX, TFLite

4. ÇÖZÜMÜN SINANMASI — 20 PUAN

Bu bölümde modelin ve sistemin nasıl test edildiği kanıtlarıyla sunulmalıdır. Sadece “model başarılıdır” demek yeterli değildir. Hangi veriyle, hangi metrikle, hangi ortamda, hangi sonuçların alındığı açıkça verilmelidir.

4.1. Test Katmanları

Proje yalnızca model metriğiyle test edilmemiştir. Birden fazla test katmanı kullanılmıştır:

Test Katmanı	Amaç
Model bbox testi	Dedektörün sınıf bazlı tespit başarısını ölçmek
Yazılım regresyon testleri	Şema, takip, QoD, WebRTC ve telemetri davranışlarını doğrulamak
Smoke test	Uçtan uca video işleme ve JSON üretimini doğrulamak
CPU benchmark	Çevrimdışı hattın CPU performansını ölçmek
OCR latency testi	OCR modellerinin gecikmesini ölçmek
Model hash testi	Kullanılan model dosyalarının değişmediğini doğrulamak
JSON schema testi	Resmi çıktının yarışma formatına uyduğunu doğrulamak

4.2. Global Model Metrikleri

Özel YOLOv8m dedektörü için ölçülen global metrikler aşağıdaki gibidir:

Metrik	Değer
Precision	0,7930

Metrik	Değer
Recall	0,7510
F1-Score	0,7714
mAP@0.50	0,7457
mAP@0.50:0.95	0,4710

Bu sonuçlar modelin genel tespit başarısını göstermektedir. Ancak sınıf dengesizliği nedeniyle global metriklerin tek başına yeterli olmadığı belirtilmelidir. Bu nedenle sınıf bazlı metrikler ayrıca raporlanmalıdır.

4.3. Sınıf Bazlı Metrikler

Sınıf	Destek	Precision	Recall	AP50	AP50-95	Yorum
telefonla_konusma	0	0,000	0,000	0,000	0,000	Test desteği yok
su_icme	4	1,000	0,000	0,000	0,000	Çok düşük destek
arkaya_bakma	1	0,723	1,000	0,995	0,498	Tek örnek, genellenemez
esneme	198	0,948	0,737	0,803	0,474	Ölçülebilir destek
sigara_icme	1.403	0,829	0,887	0,881	0,545	Global metriği baskın etkiler
emniyet_kemer_ihlali	10	0,296	0,900	0,801	0,443	Precision düşük, destek sınırlı
teknocan	0	0,000	0,000	0,000	0,000	Test desteği yok
bilgisayar	0	0,000	0,000	0,000	0,000	Test desteği yok
license_plate	128	0,960	0,984	0,994	0,867	Plaka kutusu başarısı; OCR değil

Bu tablo raporda mutlaka yer almalıdır. Çünkü jürinin güvenini artıran şey yalnızca yüksek metrik göstermek değil, metriklerin sınırlarını dürüst biçimde açıklamaktır.

4.4. Yazılım Testleri

Sistemin yazılım bileşenleri regresyon testleriyle doğrulanmıştır. Testler şu alanları kapsamaktadır:

- Resmi JSON sözleşmesi,
- enum ve şema kontrolleri,
- atomik yazım,
- plaka normalizasyonu,
- takip kimliği,
- zaman damgalı hız kestirimi,
- OAuth/Number Verification hata davranışı,
- QoD hard-gate,

- WebRTC sinyalleşmesi,
- BFF medya sınırı,
- kapasite-1 latest-frame kuyruğu,
- telemetri,
- model manifesti.

Toplam 39 testin 39'u başarıyla geçmiştir. Bu sonuç, yalnızca modelin değil, sistemin çevresindeki mühendislik katmanlarının da test edildiğini gösterir.

4.5. Smoke Test ve Uçtan Uca Çalışma

Smoke test kapsamında kısa bir video işlenmiş ve sistemin uçtan uca `results.json` üretebildiği doğrulanmıştır. Test çıktısı JSON Schema doğrulamasından geçmiştir.

CPU ortamında yapılan beş koşunun süreleri yaklaşık olarak şu şekildedir:

Koşu	Süre
1	15,201 sn
2	15,314 sn
3	15,212 sn
4	15,105 sn
5	15,126 sn
Ortalama	15,1916 sn

Hedef süre 8 saniye olduğu için CPU ortamında bu hedef karşılanmamıştır. Bu sonuç raporda açıkça belirtilmelidir. T4 GPU veya resmi NVIDIA ortamında ayrıca benchmark alınması gereklidir.

4.6. OCR Testleri

OCR için gecikme ölçümü yapılmıştır ancak doğruluk ölçümü henüz tamamlanmamıştır.

OCR Testi	Sonuç
CPU FP32 p50 latency	59,65 ms
CPU FP32 p95 latency	396,51 ms
INT8 p50 latency	250,81 ms

Bu sonuçlar OCR hızını gösterir; ancak OCR doğruluğunu göstermez. Bu nedenle raporda OCR için ayrıca CER ve tam plaka doğruluğu ölçülmesi gerektiği belirtilmelidir.

Önerilen OCR doğruluk metrikleri:

Metrik	Açıklama
CER	Karakter hata oranı

Metrik	Açıklama
Tam plaka doğruluğu	Plakanın tamamen doğru okunma oranı
İl kodu doğruluğu	İlk iki hanenin doğru okunma oranı
Sentinel oranı	OCR'ın geçersiz sayılıp sentinel'e düştüğü oran
OCR latency p50/p95	OCR çalışma süresi

4.7. FPS ve Gecikme Ölçümü

Canlı sistem için FPS ve gecikme ölçümleri önemlidir. Raporda aşağıdaki metriklerin verilmesi önerilir:

Metrik	Açıklama
FPS	Saniyede işlenen kare sayısı
Inference latency p50	Model çıkarımının medyan süresi
Inference latency p95	En kötüye yakın gecikme davranışı
End-to-end latency	Kameradan sonuca kadar toplam süre
Dropped frame oranı	İşlenmeden atılan kare oranı
WebRTC RTT	Ağ gecikmesi
Jitter	Ağ kararsızlığı

Bu metrikler Android-GPU canlı sistemde mutlaka toplanmalıdır. Eğer henüz ölçülmediyse “hedef” olarak ayrılmalıdır.

4.8. Çözümümüze Neden Güveniyoruz?

Bu soruya verilecek yanıt somut kanıtlara dayanmalıdır.

Güven Nedeni	Kanıt
Model dosyaları kilitlidir	SHA-256 hash kontrolü yapılmıştır.
Çıktı şemaya uygundur	JSON Schema doğrulaması uygulanır.
Şema dışı alanlar engellenir	<code>additionalProperties=false</code> kullanılır.
JSON atomik yazılır	Geçici dosya, flush, fsync ve replace uygulanır.
OCR belirsizliği saklanmaz	Geçerli OCR yoksa sentinel değer döndürülür.
Düşük destekli sınıflar gizlenmez	Sınıf bazlı destek tablosu verilir.
Yazılım bileşenleri testlidir	39/39 regresyon testi geçmiştir.
FTR hattı ağsız çalışır	Yarışma değerlendirmesi dış servislere bağımlı değildir.
QoD kontrollü tetiklenir	Hard-gate yaklaşımı kullanılır.

CPU performans eksiği saklanmaz 8 sn hedefinin karşılanmadığı açıkça belirtilir.

Bu bölümde güçlü bir cümle olarak şu kullanılabilir:

SİNAPTİC5G'ye güvenmemizin nedeni yalnızca modelin belirli bir mAP değerine ulaşması değildir. Sistemin güvenilirliği; model dosyalarının hash ile kilitlenmesi, çıktıların JSON Schema ile doğrulanması, atomik yazım yapılması, belirsiz OCR sonuçlarında sentinel davranışı uygulanması, düşük destekli sınıfların açıkça raporlanması ve yazılım bileşenlerinin regresyon testleriyle korunması sayesinde sağlanmaktadır.

5. KAYNAKÇA — 5 PUAN

Kaynakça bölümünde yalnızca akademik makaleler değil, kullanılan veri setleri, GitHub repoları, kütüphaneler, framework dokümanları, 5G/CAMARA API dokümanları ve yarışma dokümanları da verilmelidir.

5.1. Açık Kaynak Kütüphaneler ve Frameworkler

- Ultralytics. "Ultralytics YOLO." GitHub Repository. Kullanım amacı: YOLOv8 tabanlı nesne tespiti ve model eğitimi.
- Microsoft. "ONNX Runtime Documentation." Kullanım amacı: ONNX formatındaki modellerin CPU/GPU üzerinde çalıştırılması.
- OpenCV. "Open Source Computer Vision Library." Kullanım amacı: video okuma, görüntü işleme, renk uzayı dönüşümü ve ön işleme.
- Python jsonschema. Kullanım amacı: `results.json` çıktısının resmi JSON Schema'ya göre doğrulanması.
- FastAPI. Kullanım amacı: BFF ve canlı servis API katmanları.
- Redis. Kullanım amacı: kısa ömürlü SDP/ICE posta kutusu ve QoD kilit mekanizması.
- aiortc. Kullanım amacı: Python tarafında WebRTC sinyalleşmesi ve medya işleme.
- Android Developers CameraX. Kullanım amacı: Android kamera görüntüsünün alınması.
- TensorFlow Lite / LiteRT. Kullanım amacı: alternatif mobil/edge model çalıştırma senaryoları.

5.2. 5G ve CAMARA Kaynakları

- CAMARA Project. "Quality on Demand API." Kullanım amacı: canlı risk senaryolarında ağ kalitesi talebinin yönetilmesi.
- CAMARA Project. "Number Verification API." Kullanım amacı: mobil cihaz/numara doğrulama senaryosu.
- WebRTC dokümantasyonu. Kullanım amacı: düşük gecikmeli canlı medya aktarımı.
- OAuth/JWT dokümantasyonu. Kullanım amacı: kimlik ve oturum güvenliği.

5.3. Veri Setleri

- Roboflow Universe. "Driver Distraction Detection." Kullanım amacı: telefon, su içme, arkaya bakma gibi sürücü dikkat dağınıklığı davranışları.
- Roboflow Universe. "Driver Drowsiness YOLO." Kullanım amacı: esneme/yorgunluk davranışı.

- Roboflow Universe. "Cigarette Smokers." Kullanım amacı: sigara içme davranışı.
- Roboflow Universe. "Detect Seatbelt." Kullanım amacı: emniyet kemeri ihlali.
- Kaggle. "Turkish License Plate Dataset." Kullanım amacı: Türkiye plaka bölgesi tespiti.

Her veri seti için kaynakçada şu bilgiler verilmelidir:

Bilgi	Açıklama
Veri seti adı	Kullanılan veri setinin tam adı
Platform	Roboflow, Kaggle vb.
Sürüm	Varsa veri seti versiyonu
URL	Veri seti bağlantısı
Lisans	CC BY 4.0, CC0 vb.
Kullanım amacı	Hangi sınıf veya görev için kullanıldığı
Erişim tarihi	Raporun hazırlandığı tarih

5.4. Yarışma Dokümanları

Kaynakçada yarışma dokümanları da belirtilmelidir:

- TEKNOFEST / Turkcell 5G ve Yapay Zekâ ile Akıllı Yol Güvenliği Yarışması Final Tasarım Raporu Şablonu.
- FTR aşaması teslim dokümantasyonu.
- Yarışma çıktı formatı ve değerlendirme kuralları.
- Varsa resmi örnek veri, örnek çıktı veya teknik şartname.

5.5. Kaynakça Yazımında Dikkat Edilecekler

Kaynakça bölümü yalnızca link listesi gibi bırakılmamalıdır. Her kaynağın projede hangi amaçla kullanıldığı belirtilmelidir. Örneğin:

Yanlış kullanım:

<https://github.com/ultralytics/ultralytics>

Doğru kullanım:

Ultralytics. "Ultralytics YOLO." GitHub Repository.
 URL: <https://github.com/ultralytics/ultralytics>
 Kullanım amacı: YOLOv8m tabanlı özel dedektör eğitimi ve YOLOv8n COCO modelinden yararlanma.
 Erişim tarihi: 20.06.2026.

Bu şekilde yazıldığında jüri, her kaynağın projedeki yerini daha net görür.

RAPORDA EKLENMESİ GEREKEN GÖRSEL VE TABLOLAR

Raporun güçlü görünmesi için aşağıdaki görsel ve tablolar eklenmelidir:

Tablo Önerileri

Tablo	Bölüm
Proje bileşenleri tablosu	Proje Özeti
Veri kaynakları ve lisans tablosu	Veri Seti
Kanonik sınıf sözlüğü	Veri Seti
Train/val/test dağılımı	Veri Seti
Sınıf destek histogramı	Veri Seti
Model eğitim parametreleri	Çözüm Detayları
Global metrik tablosu	Çözümün Sınanması
Sınıf bazlı metrik tablosu	Çözümün Sınanması
CPU/GPU benchmark tablosu	Çözümün Sınanması
OCR doğruluk/gecikme tablosu	Çözümün Sınanması
“Ölçüldü / Hedef / Uyarı” tablosu	Proje Özeti veya Sonuç

Diyagram Önerileri

Diyagram	Amaç
Çevrimdışı FTR pipeline diyagramı	Video girişinden <code>results.json</code> çıktısına kadar süreci göstermek
Canlı 5G/WebRTC mimari diyagramı	Android, GPU, BFF, Redis ve CAMARA ilişkisini göstermek
Veri düzlemi / kontrol düzlemi ayrımı	Ham videonun nereden geçtiğini ve nereden geçmediğini göstermek
QoD hard-gate karar akışı	QoD'nin hangi şartlarda çağrıldığını göstermek
Takip pipeline diyagramı	IoU, BEV, HSV ve Kalman birleşimini anlatmak
OCR karar diyagramı	Plaka crop → OCR → regex → sentinel akışını göstermek

Grafik Önerileri

Grafik	Amaç
Sınıf bazlı instance dağılımı	Veri dengesizliğini göstermek
Precision/Recall/F1 bar grafiği	Model genel başarısını göstermek
AP50 sınıf bazlı bar grafiği	Hangi sınıfların güçlü/zayıf olduğunu göstermek
Latency p50/p95 grafiği	Performans değerlendirmesi yapmak
Hata analizi örnekleri	False positive / false negative durumlarını göstermek

RAPORUN GENEL ANLATIM STRATEJİSİ

Bu raporda en güçlü anlatım stratejisi şudur:

1. Projenin yalnızca model değil, uçtan uca sistem olduğunu göster.
2. Her iddiayı ölçüm veya dosya kanıtına bağla.
3. Ölçülmeyen şeyleri başarı gibi sunma.
4. Düşük destekli sınıfları saklama.
5. OCR ve T4 gibi eksikleri "hedef" olarak açıkça ayır.
6. 5G tarafını sadece API entegrasyonu değil, kontrollü ağ kaynağı yönetimi olarak anlat.
7. Jüriye güven veren mühendislik detaylarını öne çıkar: hash, schema, atomik yazım, sentinel, testler.

Sonuçta raporun ana mesajı şu olmalıdır:

SİNAPTİC5G, yalnızca video üzerinde nesne tespiti yapan bir model değil; veri seti yönetimi, model çıkarımı, takip, plaka doğrulama, güvenli çıktı üretimi, WebRTC tabanlı canlı medya aktarımı ve CAMARA tabanlı 5G ağ orkestrasyonunu birleştiren, kanıta dayalı ve denetlenebilir bir yol güvenliği sistemidir.