



5G & YAPAY ZEKA İLE AKILLI YOL GÜVENLİĞİ YARIŞMASI ÖN TASARIM RAPORU ŞABLONU

Takım Adı:

SinapticLink5G

Takım ID:

989764

Başvuru ID:

5205583



İÇİNDEKİLER

5G & YAPAY ZEKA İLE AKILLI YOL GÜVENLİĞİ YARIŞMASI ÖN TASARIM RAPORU ŞABLONU	1
1. PROJE ÖZETİ	3
2. TAKIM ŞEMASI	3
3. SİSTEM ÖN TASARIMI	3
3.1. Genel Sistem Mimarisi ve Veri Akış Şeması	3
3.2. Yapay Zeka Modeli ve Çıkarım Tasarımı	3
3.3. Yazılım Mimari Tasarımı	3
4. YÖNTEM	4
5. ÖZGÜNLÜK	4
6. ZAMAN PLANLAMASI	4
7. PROJE RAPOR DÜZENİ VE KAYNAKÇA	4



1. PROJE ÖZETİ


Sinaptic5G projesi kapsamında, 5G şebekesinin programlanabilir **Quality on Demand (QoD)** yetenekleri uçtan uca yapay zeka çıkarım hattı ve **Multi-Access Edge Computing (MEC)** mimarisi ile entegre edilerek risk odaklı bir akıllı yol güvenliği altyapısı tasarlanmış ve geliştirilmiştir. Proje faaliyetleri; Android edge katmanında **YOLOv8-nano** (INT8 quantize + bilgi damıtma) ve **Zero-DCE** ön işleme ile gerçek zamanlı nesne tespiti, **DeepSORT** tabanlı çoklu nesne takibi ve temporal action recognition (16-32 kare pencere, $N \geq 8$ debounce) ile sürücü davranışlarının eylem dizisi olarak sınıflandırılması üzerine kurgulanmıştır. Beş boyutlu QoD karar motorunun geliştirilmesi ve **Turkcell Open Gateway API** entegrasyonu ile kritik eşik aşımında tek seferlik şebeke kalitesi garanti oturumu talep eden **Redis tabanlı state machine mekanizması** oluşturulmuştur. MEC katmanında Redis Streams **producer-consumer** mimarisi üzerinden asenkron worker'lar paralel olarak yapılandırılmış; bu katmanda **YOLOv8-large**, **LPRNet+CRNN** tabanlı otomatik plaka tanıma ve hibrit anlık hız+ivme analiz modülleri yalnızca risk bağlamına göre tetiklenmektedir. Ayrıca **dinamik kare atlama**, **adaptif ROI kırpmaya** ve Redis **TTL tabanlı** alert suppression modülleri ile kaynak optimizasyonu sağlanmış, **WebRTC** ve **WebSocket** protokol seçimi ile düşük gecikmeli kare aktarımı entegre edilmiştir. Geliştirilen uçtan uca mimari, bant genişliği ve işlem yükünü yalnızca analiz doğruluğunun tehdit altında olduğu anlarda aktive ederek 60-120 ms gecikme, $\geq 72\%$ edge mAP ve $\leq 8\%$ **ALPR CER** hedeflerini karşılayan; şebeke ve YZ katmanlarını çift yönlü geri besleme döngüsüyle yöneten özgün bir sistem ortaya koymaktadır.

2. TAKIM ŞEMASI

SAYI	TAKIMDAKİ GÖREVİ	EĞİTİM SEVİYESİ	SINIF	ÜYE ROLÜ
1	Takım Kaptanı / Backend & YZ Entegrasyon Sorumlusu	Lisans / Bilgisayar Mühendisliği	4. Sınıf	Kaptan
2	UI/UX Tasarım & Kullanıcı Deneyimi Sorumlusu	Lisans / Mimarlık	2. Sınıf	Üye

3. SİSTEM ÖN TASARIMI

3.1. Genel Sistem Mimarisi ve Veri Akış Şeması



Sinaptic5G, Edge (Mobil) – 5G Ağ – MEC Sunucu – Arayüz/Veri katmanlarından oluşur.

Darboğaz önleme:

Dinamik kare atlama ile ROI kırpmaya birlikte kullanıldığında bant genişliği ve MEC üzerindeki işlem yükü %60-70 oranında azalıyor. Redis Streams tabanlı asenkron kuyruk yapısı sayesinde worker'lar

birbirinden bağımsız çalışıyor; birinin yavaşlaması diğerlerini etkilemiyor. Tek oturum politikası ve uyarı bastırma mekanizması (plaka için 60 saniye, eylem için 30 saniye TTL) ile API sinyalleşme yükü ve tekrarlayan bildirimler ortadan kalkıyor. Tüm bunların sonucunda, değişken 5G koşullarında bile uçtan uca gecikme 60-120 ms aralığında garanti edilebiliyor.

3.2. Yapay Zeka Modeli ve Çıkarım Tasarımı

Yapay zeka mimarisi YOLOv8 üzerine kuruluyor; hız ve doğruluk dengesini tek aşamalı yapısıyla sağlıyor. İkili bir hiyerarşi var: uç cihazlarda sürekli çalışan YOLOv8-nano (INT8, ~3.2M parametre, NNAPI ile hızlandırılmış), MEC tarafında ise yalnızca kalite odaklı oturumlar aktifken YOLOv8-large (FP16, TensorRT) devreye giriyor.

Model, BDD100K, UA-DETRAC ve CCPD veri setleriyle ön eğitimden geçiyor; üzerine sigara içme, telefonla konuşma, sağ-sol bakma, oyuncak nesnesi ve TOGG gibi ek sınıflar ekleniyor. Zaman boyutlu eylemler için 16-32 karelik pencere üzerinden 1D CNN + LSTM kullanılıyor. Plaka tanımda LPRNet ve CRNN (CTC loss) birlikte çalışıyor; CLAHE ile kontrast artırılıyor ve Türkçe regex ile doğrulama yapılıyor.

Doğruluk ve gecikme optimizasyonu üç katmanda ilerliyor:

- **INT8 + Knowledge Distillation:** Nano model yaklaşık 4 kat küçülüyor, 2 kat hızlanıyor. mAP kaybı, YOLOv8-large öğretmen modelden logit ve öznetelik haritası damıtılarak +3-5 puan telafi ediliyor.
- **Temporal debounce + durum makinesi:** Bir eylemin teyidi için en az 8 ardışık kare gerekiyor. IDLE → SUSPECT → CONFIRMED → COOLDOWN geçişleriyle anlık gürültü filtrelenecek, yanlış pozitifler azalacak.
- **Hibrit hız + ivme:** Son hız, %60 DeepSORT ve %40 Farneback optik akış birleşimiyle hesaplanıyor. EMA yumuşatma ve MAD aykırı değer reddi ile kutu titremesi ve akış gürültüsü bastırılıyor. İvme ve jerk istatistikleri ihlal tespitinde kullanılıyor.

Uçtan uca çıkarım iş hattı (bileşen tablosu):

Bileşen	Model	Eğitim Verisi	Optimizasyon	Tetikleyici / Koşul	Çıktı
Düşük Işık Geliştirme	Zero-DCE TFLite	ExDark, LOL	Mobil quantize	mean_Y < 40	Normalize frame
Edge Tespit	YOLOv8-nano	BDD100K, UA-DETRAC, proje	INT8+KD, NNAPI	Her frame	BBox listesi
MEC Tespit	YOLOv8-large	COCO, BDD100K,	TensorRT, FP16, batch	Yüksek yük durumu	BBox + conf
Nesne Takibi	DeepSORT	Proje videoları	Kalman, Re-ID	Her frame	Track ID + trajectory


Eylem Tanıma	1D CNN+LSTM / SlowFast	Proje + NTU RGB+D	16-32 pencere	N≥8 debounce	Eylem etiketi
Plaka Tanıma	LPRNet + CRNN (CTC)	CCPD, proje ROI	CLAHE, Türk regex	Risk tetikli	Plaka metni
Hız & İvme	DeepSORT + Farneback	Proje videoları	$\alpha=0.6$ hibrit, EMA, MAD	Her track	km/h, m/s ²

3.3. Yazılım Mimari Tasarımı

Mobil uygulama (ön yüz): Kotlin tabanlı ön yüz, CameraX ve TFLite Runtime + NNAPI ile NPU/DSP hızlandırmalı çıkarım yaparken; Retrofit + OkHttp üzerinden QoD API'ye ve WebRTC/WebSocket istemcisine bağlanır, Room (SQLite) ile ağ kesintilerinde logları tamponlayıp bağlantı sağlandığında PostgreSQL ile senkronize eder.

MEC sunucu (arka yüz) & eşzamanlı istek yönetimi: FastAPI + asyncio ile asenkron çalışan MEC sunucusu, gelen kareleri Redis Streams üzerinde producer olarak işler; dört bağımsız worker (YOLO-large, Action Validation, ALPR, Hız+İvme) consumer group mantığıyla paralel tüketir, QoD API çağrılarını inference'tan izole eder ve Redis SETEX/SETNX kilitleriyle oturum yönetimini, PostgreSQL ile kalıcı loglamayı sağlar.

Kullanıcı arayüzleri:




Donanım & yazılım bileşen tablosu (kritik teknolojiler):

Bileşen	Teknoloji	Versiyon	Katman	Görev	Gecikme Katkısı
---------	-----------	----------	--------	-------	-----------------


Mobil uygulama	Kotlin/Android SDK	API 33+	Edge	Kamera, UI, edge inference	—
Edge YZ	TensorFlow Lite	2.14+	Edge	YOLOv8-nano INT8+KD, NNAPI	≤15ms(hedef)
MEC YZ	TensorRT	8.6+ / 1.19+	MEC	YOLOv8-large FP16, batch	≤30ms(hedef)
ALPR	LPRNet+CRNN (PyTorch)	—	MEC	Risk bağlamlı plaka tanıma	Risk-tetikli
Backend API	Python / FastAPI	0.115+	Backend	REST, WebRTC/WS signaling	≤5 ms
Mesaj kuyruğu	Redis Streams	7+	Backend	Producer-consumer	Async, non-blocking
Oturum/cache	Redis	7+	Backend	QoD TTL, Alert Suppression	≤1 ms
Veritabanı	PostgreSQL + asyncpg	16	Backend	Kalıcı log, geçmiş	Async I/O
Yerel depo	Room (SQLite)	2.6+	Edge	Çevrimdışı senkronizasyon tampon,	—
İşleme	OpenCV	4.10+	Edge/MEC	CLAHE, Laplacian, Farneback, MAD	≤5 ms
Nesne takibi	DeepSORT	—	Edge/MEC	Track ID, Kalman, debounce	Pipeline içi
Akış protokolü	WebRTC/WebSocket	—	Ağ	Adaptif düşük gecikmeli video	≤10 ms
Auth / API	Retrofit + OkHttp	2.9+	Edge	Open Gateway entegrasyonu	—

4. YÖNTEM


AŞAMA 1 – Veri Hazırlığı, Etiketleme, Kalibrasyon




AŞAMA 2 – YZ Modeli Geliştirme ve Optimizasyon



AŞAMA 3 – 5G API Entegrasyonu ve QoD Yönetimi



AŞAMA 4 – Mobil Uygulama, MEC Kuyruk ve Asenkron Pipeline



AŞAMA 5 – Uçtan Uca Entegrasyon, Validasyon ve Final Teslimi

Gelecek Ürün Fikirleri: *Sinaptic5G Fleet* (filo yönetimi), *Guard* (bölge koruma, yasal kanıt), *Insight* (sigorta telematiği, risk bazlı primlendirme).

6. ZAMAN PLANLAMASI (5 PUAN)

Proje, yarışmadaki 5 aşamayı kapsayacak şekilde Agile (2 haftalık sprint) ile yürütülür. Süreç takibi, backlog ve retrospektifler için Trello kullanılır.

Sprint Planlaması ve Çıktıları

Sprint	Tarih	Kapsam	Temel Çıktı
0	27Mart–3 Nisan	Video analizi, temporal etiketleme, ortam kurulumu	Etiketli veri seti, Roboflow, kalibrasyon raporu
1	4Nisan–17 Nisan	Fine-tuning, INT8 optimizasyon, temporal action modeli	Optimize modeller (.tflite/.pt), KPI tablosu
2	18Nisan–01 Mayıs	FastAPI MEC, Redis Streams, WebRTC/WS altyapısı	MEC backend, producer-consumer, API testleri
3	02Mayıs–15 Mayıs	Turkcell Open Gateway, QoD state machine, tek oturum politikası	Entegrasyon raporu, debounce doğrulama, gecikme logu
4	16Mayıs–29 Mayıs	Android:dinamik,FPS/ROI, DeepSORT, AlertSuppressor, UI/UX	Alfa APK, test raporları
5	30 Mayıs–12 Haziran	Uçtan uca entegrasyon, stres testi, optimizasyon	Beta APK, uçtan uca test raporu, performans profili
6	13Haziran–26 Haziran	Final dokümantasyon, sunum, demo video	Tasarım raporu, jüri sunumu, demo

Faz Bağımlılıkları: Projenin faz bağımlılıkları Sprint 0 → 1 → 2 → 5 ana omurgasında ilerlerken, Sprint 3 (5G API) ve Sprint 4 (Android) paralel yürütülerek Sprint 5'in ön koşullarını tamamlar; böylece disiplinler arası iş bölümü netleşir ve süre optimizasyonu sağlanır.

Risk Yönetimi:Risk yönetimi kapsamında API gecikmesi mock gateway ile paralel geliştirme, model doğruluğu düşüşü KD hiperparametre optimizasyonu ve kuyruk tıkanıklığı Redis consumer group ölçeklendirme ile yönetilir; tüm riskler sprint retrospektiflerinde gözden geçirilip gerekirse kapsam dinamik olarak güncellenir.

Risk Başlığı	Olası Etki	Önlem Stratejisi	İzleme Yöntemi
--------------	------------	------------------	----------------

API gecikmesi	Şebeke entegrasyonunda zaman kaybı	Mock gateway ile paralel geliştirme	Sprint retrospektiflerinde gecikme analizi
Model doğruluğu düşüşü	Eylem tanıma ve plaka tespitinde hata artışı	KD hiperparametre optimizasyonu	mAP ve F1 skorlarının per-sprint takibi
Kuyruk tıkanıklığı	MEC iş yükü dengesizliği, işlem gecikmesi	Redis consumer group ölçeklendirme	Kuyruk doluluk oranı ve latency grafikleri

Test & Validasyon: Her sprint sonunda birim testleriyle doğrulama yapılır, Sprint 5'te uçtan uca entegrasyon, stres ve offline senaryo testleri gerçekleştirilir; tüm süreç GitHub Actions üzerinden CI/CD test otomasyonu ile sürekli ve tekrarlanabilir mühendislik güvencesi altına alınır.

7. PROJE RAPOR DÜZENİ VE KAYNAKÇA

- [1] J. Carreira and A. Zisserman, "Quo Vadis, Action Recognition? A New Model and the Kinetics Dataset," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 6299–6308.
- [2] L. Chen et al., "Real-time Vehicle Detection and Tracking in Low-light Conditions: A Survey," *IEEE Transactions on Intelligent Transportation Systems*, vol. 24, no. 3, pp. 2891–2908, Mar. 2023, doi: 10.1109/TITS.2022.3221853.
- [3] C. Guo et al., "Zero-Reference Deep Curve Estimation for Low-Light Image Enhancement," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2020, pp. 1780–1789.
- [4] G. Hinton, O. Vinyals, and J. Dean, "Distilling the Knowledge in a Neural Network," in *NIPS Deep Learning and Representation Learning Workshop*, 2015.
- [5] A. Howard et al., "Searching for MobileNetV3," in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2019, pp. 1314–1324.
- [6] T. C. Hui and J. Zheng, "LPRNet: License Plate Recognition via Deep Neural Networks," *arXiv preprint arXiv:1806.10447*, 2018.
- [7] M. S. Islam, M. S. Hossain, and S. Hossain, "Deep Learning-Based Action Detection in Untrimmed Videos: A Survey," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 45, no. 4, pp. 4302–4324, Apr. 2023, doi: 10.1109/TPAMI.2022.3193611.
- [8] Y. LeCun, Y. Bengio, and G. Hinton, "Deep Learning," *Nature*, vol. 521, no. 7553, pp. 436–444, May 2015, doi: 10.1038/nature14539.
- [9] S. Ren, K. He, R. Girshick, and J. Sun, "Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 39, no. 6, pp. 1137–1149, Jun. 2017, doi: 10.1109/TPAMI.2016.2577031.
- [10] B. Shi, X. Bai, and C. Yao, "An End-to-End Trainable Neural Network for Image-based Sequence Recognition and its Application to Scene Text Recognition," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 39, no. 11, pp. 2298–2304, Nov. 2017, doi: 10.1109/TPAMI.2016.2646371.